INSTITUTO DE INFORMÁTICA
UFRGS

MONITORAMENTO DE SEGURANÇA EM CANTEIROS DE OBRA UTILIZANDO INFERÊNCIA MULTIESTÁGIO EM INTELIGÊNCIA ARTIFICIAL NA BORDA

Luiz Guilherme Martinho Sampaio Ito

Orientador: Prof. Dr. José Rodrigo Furlanetto de Azambuja

Defesa de Dissertação de Mestrado — Março de 2026

SUMÁRIO

1. Introdução

Contexto, Problema, Motivação, Hipótese

2. Objetivos

Objetivo Geral, Específicos, Contribuições, Escopo

3. Fundamentação Teórica

Detectores, YOLOv8, Transfer Learning, Jetson, DeepStream

4. Trabalhos Relacionados

Comparação com a Literatura, Lacunas

5. Metodologia

Cascata, Classes, Datasets, Augmentation, Treinamento

6. Implementação

Pipeline DeepStream, Parser C++, Software Stack, Deploy

7. Resultados

PGIE, SGIEs, Performance, Recursos, Qualitativos

8. Conclusão

Objetivos Atingidos, Limitações, Trabalhos Futuros

Construção Civil no Mundo

13%

do PIB mundial

7%

da força de trabalho global

Construção Civil no Brasil

6,2%

do PIB nacional

2,5M

trabalhadores formais

O setor lidera as estatísticas de **acidentes graves e fatais** tanto no Brasil quanto mundialmente. Quedas de altura, soterramento, choque elétrico e impacto de objetos são as principais causas.

O PROBLEMA

2,78M

mortes/ano por acidentes de trabalho

Fonte: OIT, 2024

600k

acidentes registrados no Brasil em 2022

12% na construção

<40%

taxa de detecção na vigilância manual

Teizer, 2015

Inspeções manuais são intermitentes, reativas e sujeitas a erros humanos.

Como automatizar a vigilância de segurança em canteiros de obra?

MOTIVAÇÃO — POR QUE IA NA BORDA?

Visão computacional + *deep learning* = vigilância contínua e automática.

Mas **onde** processar os dados?

Nuvem	Borda (Edge AI)
× Latência: 200–500 ms	✓ Latência: <100 ms
× Banda: 3–10 Mbps/câm	✓ Sem dependência de rede
× Falha se sem internet	✓ Privacidade local
× Custo recorrente	✓ Custo fixo (hardware)

Canteiros de obra têm conectividade instável e exigem resposta imediata.
A **computação de borda** é a escolha natural.

HIPÓTESE

Uma arquitetura de **inferência em cascata** na borda, com modelo primário generalista + modelos secundários especializados, pode monitorar segurança em **tempo real** com múltiplas categorias.

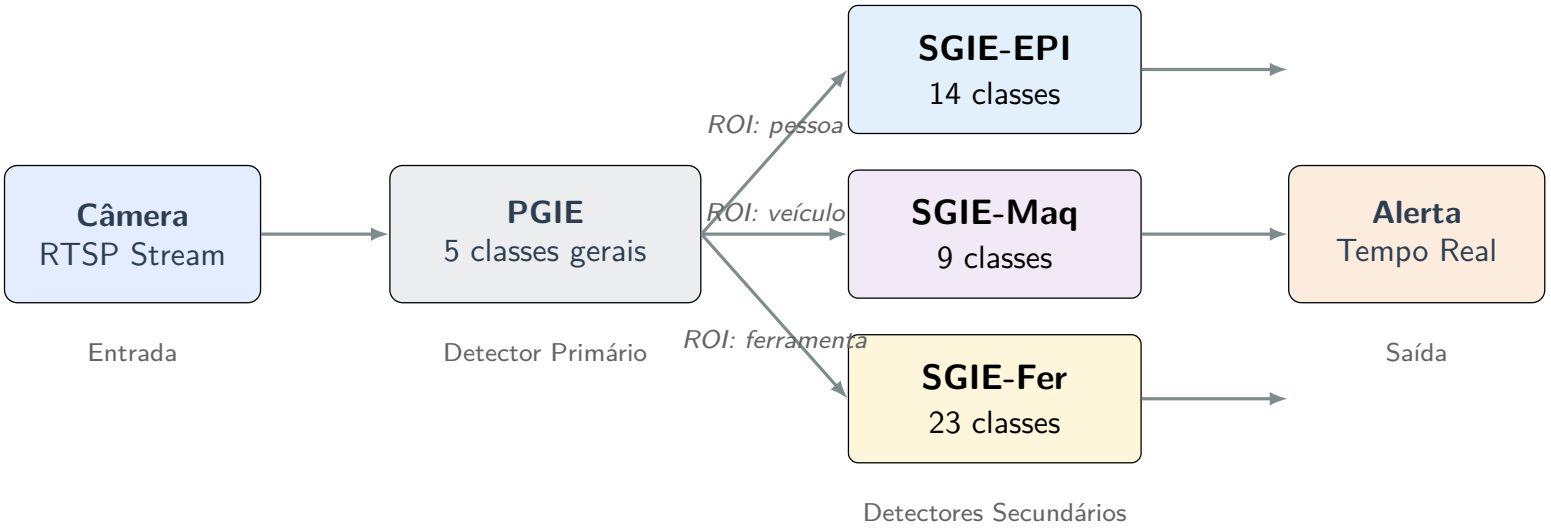

46 categorias únicas — 4 modelos YOLOv8

OBJETIVO GERAL

Projetar, implementar e validar um sistema de **análise de vídeo inteligente** baseado em **computação de borda** com inferência em cascata para monitoramento de segurança em **tempo real** em canteiros de obras.

Onde	O quê	Para quê
Edge	**20+ FPS**	**46**
Computação na borda Jetson AGX Xavier	Detecção em tempo real	Categorias de segurança monitoradas
30W | 512-core GPU	4 modelos simultâneos	EPIs, máquinas, ferramentas

OBJETIVOS ESPECÍFICOS

OE1 — Treinamento dos Modelos

- **PGIE**: 5 classes gerais (pessoa, veículo, capacete, colete, ferramenta)
- 3 **SGIEs**: EPI (14 cls) | Maquinário (9 cls) | Ferramentas (23 cls)

OE2 — Pipeline de Inferência em Cascata

- Pipeline **DeepStream SDK** com inferência multiestágio
- Decodificação → PGIE → SGIEs → visualização

OE3 — Integração YOLO–DeepStream

- Funções de *parsing* em **C++** para YOLOv8
- Roteamento automático PGIE → SGIEs por classe

OE4 — Avaliação de Desempenho

- Medir **acurácia** (mAP) de cada modelo individualmente
- Medir **velocidade** (FPS) e latência do pipeline completo
- Avaliar uso de recursos: GPU, memória, consumo energético

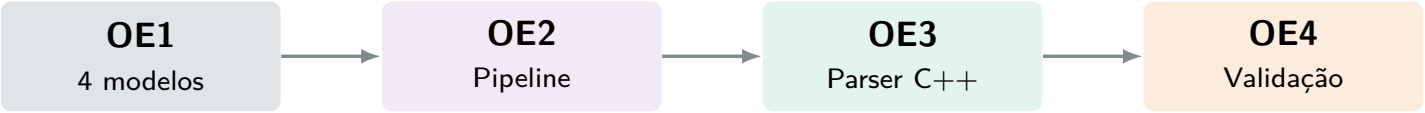

Cada objetivo específico alimenta o seguinte — fluxo sequencial de desenvolvimento.

Arquitetura em Cascata
PGIE + 3 SGIEs em ROIs
4 modelos **46** categorias

Modelos Treinados
YOLOv8 + transfer learning
FP16 precisão **mAP** validado

Pipeline DeepStream
Acelerado por TensorRT FP16
58 ms latência

Validação em Borda
Métricas reais no Jetson Xavier
20 FPS **24** W

ESCOPO DO TRABALHO

Dentro do Escopo

- ✓ Detecção de EPIs
  capacete, colete, luvas, botas, óculos...
- ✓ Detecção de maquinário
  escavadeiras, caminhões, guindastes...
- ✓ Detecção de ferramentas
  furadeiras, serras, escadas...
- ✓ Inferência em tempo real
- ✓ Execução em dispositivo de borda
- ✓ Análise de desempenho

Fora do Escopo

- × Reconhecimento de ações
  posturas perigosas, quedas
- × Rastreamento de identidade (Re-ID)
- × Integração com sistemas de gestão (ERP/BIM)
- × Deploy multi-câmera em larga escala
- × Treinamento *online* (atualização contínua)
- × Interface para usuário final

Evolução dos detectores: **Two-stage** (alta precisão) vs **Single-stage** (baixa latência)

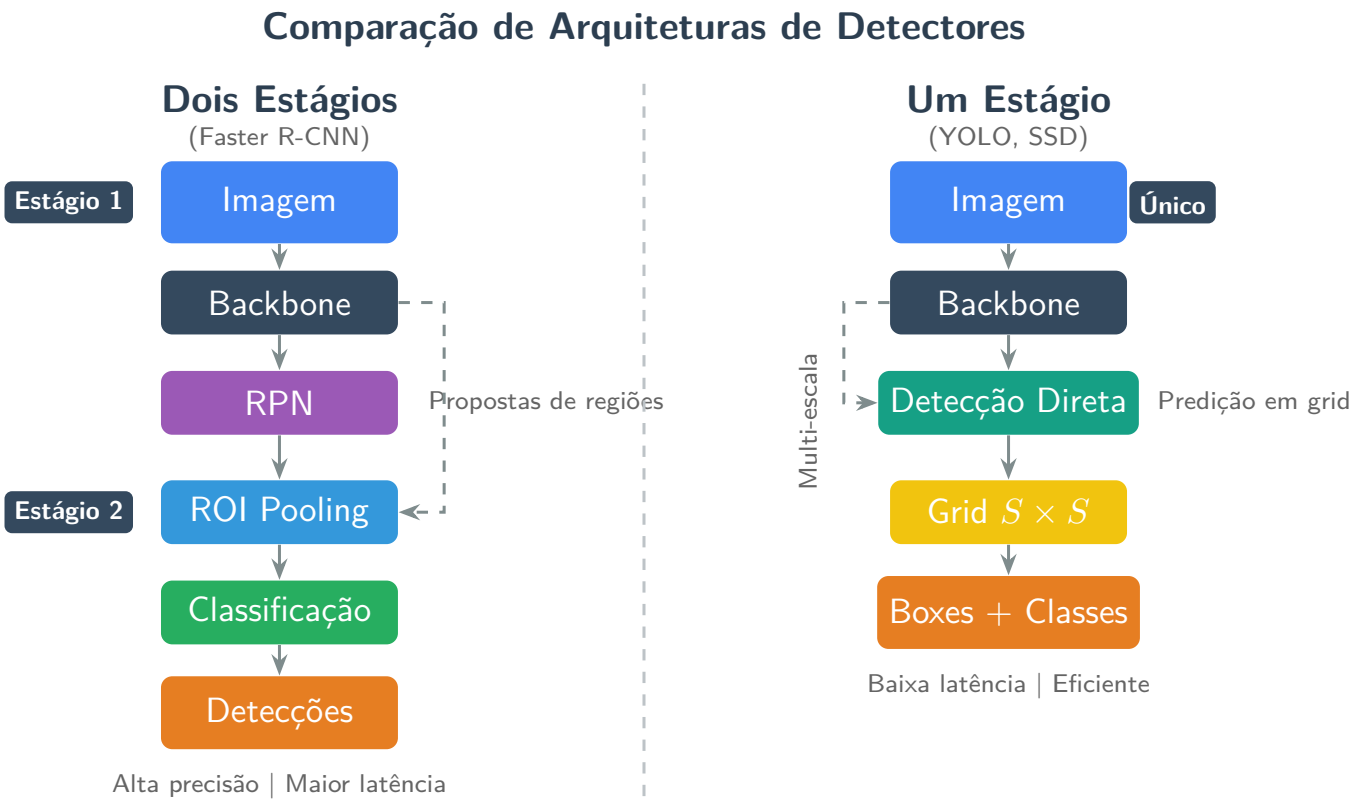

YOLO escolhido: melhor *trade-off* velocidade/acurácia para inferência em tempo real na borda

Três componentes: **Backbone** (extração) + **Neck** (fusão multi-escala) + **Decoupled Head** (detecção)

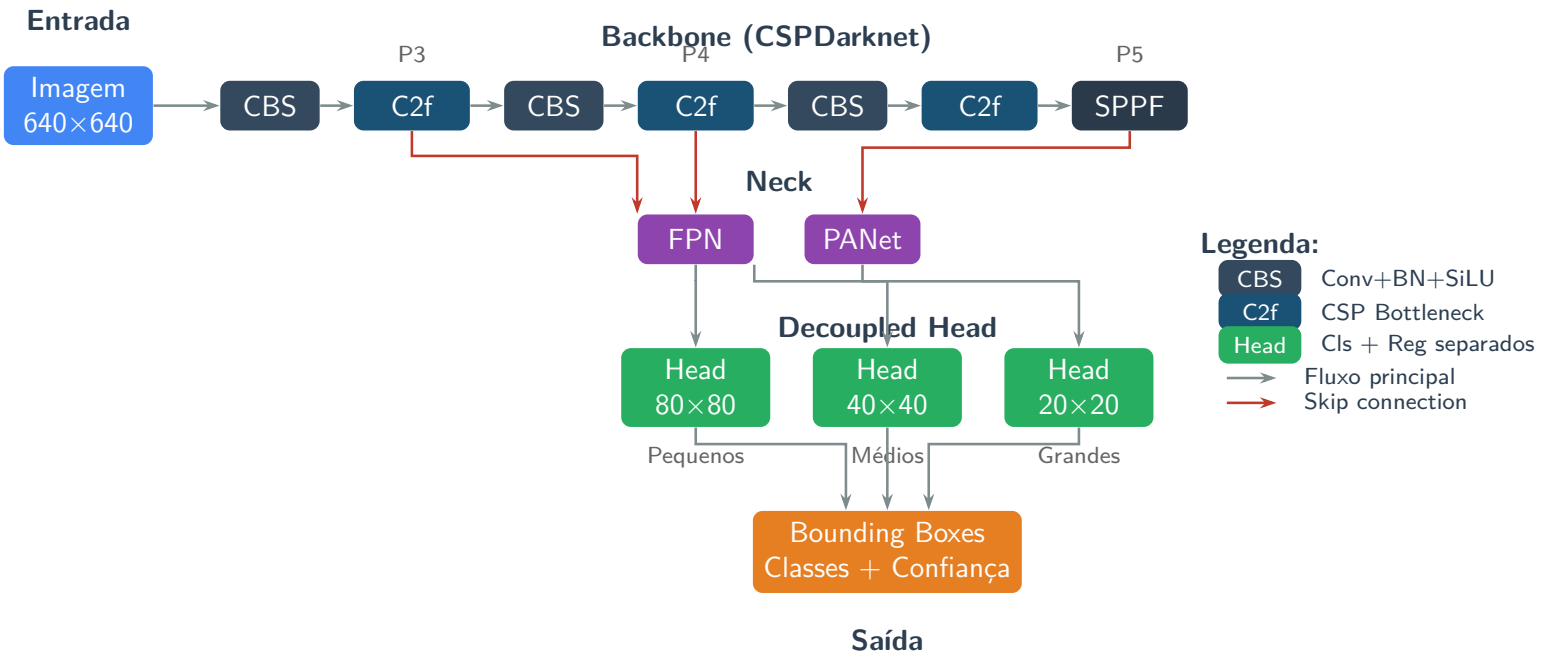

Variantes **YOLOv8s** e **YOLOv8m** utilizadas — *anchor-free* com cabeças desacopladas (cls + reg)

Reutilização de conhecimento e supressão de redundância

Transfer Learning

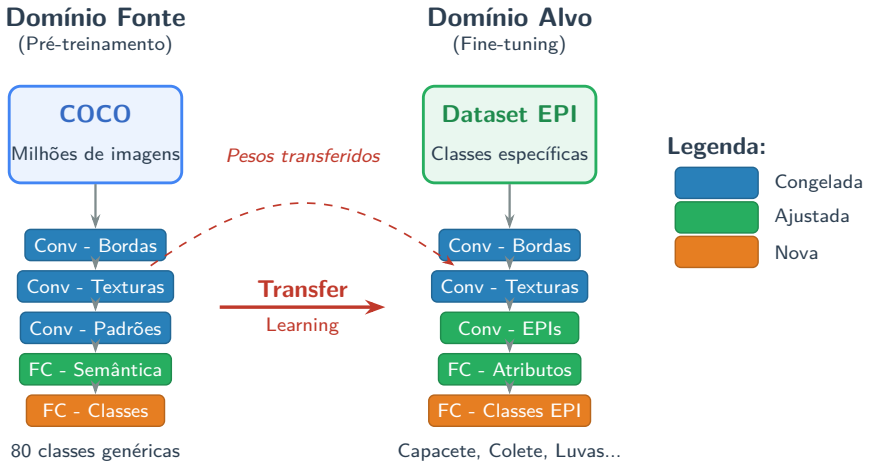

COCO → domínio específico: camadas iniciais reutilizadas.

Non-Maximum Suppression

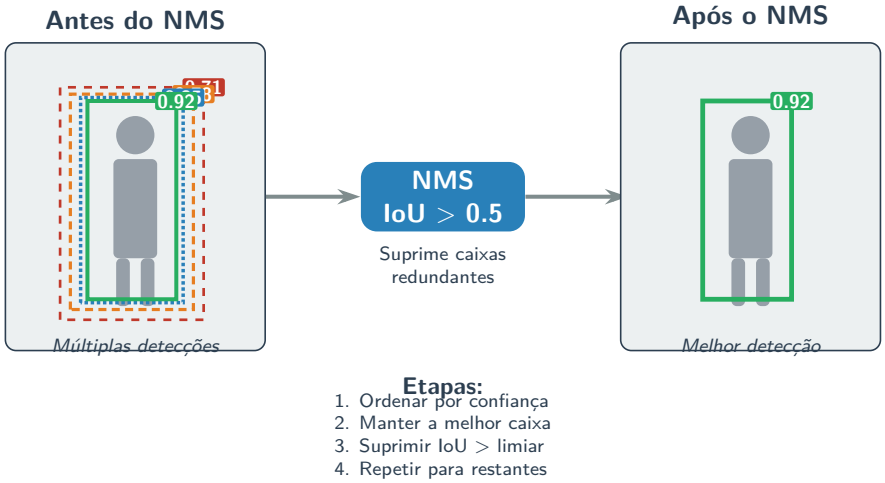

IoU > 0,5: caixas redundantes suprimidas.

Transfer learning: poucos dados — **NMS**: etapa final do pipeline YOLO

Plataforma de computação de borda para inferência de IA em tempo real

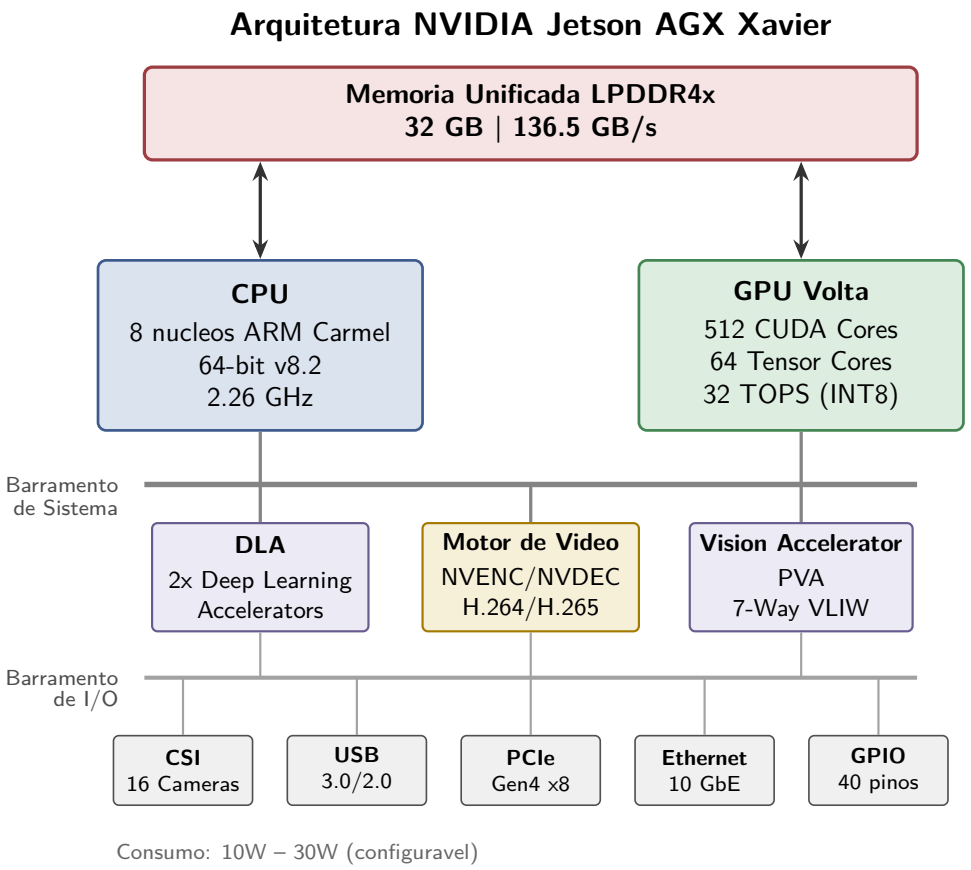

Especificações:

- **GPU Volta**: 512 CUDA + 64 Tensor Cores
- **CPU**: 8x ARM @ 2,26 GHz
- **RAM**: 32 GB LPDDR4x (136,5 GB/s)
- **IA**: 32 TOPS (INT8)
- **DLA**: 2x aceleradores dedicados
- **Consumo**: 10–30 W configurável

Escolha: equilíbrio entre desempenho e eficiência energética.

Pipeline acelerado por hardware para análise de vídeo **100% na borda**

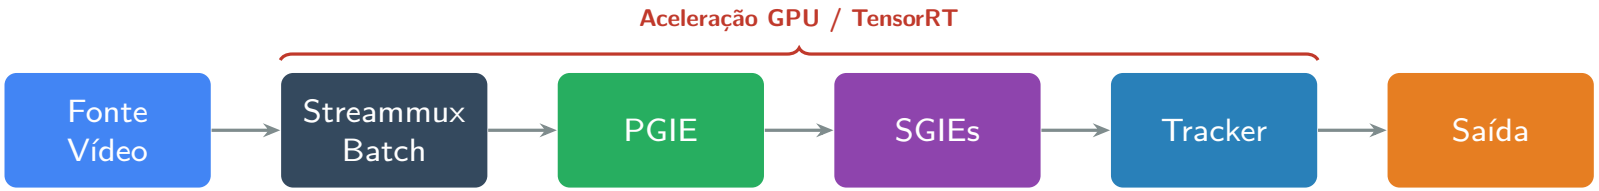

Nuvem	Borda (Edge AI)
× Latência 50–200 ms	✓ Latência <50 ms
× Requer conexão constante	✓ Opera offline
× Custo com largura de banda	✓ Dados locais (LGPD)

DeepStream: cascata nativa PGIE→SGIEs, zero-copy CPU/GPU — processamento **100% na borda**

TRABALHOS RELACIONADOS

Detecção de EPIs

- **Nath et al.** (2020)
  YOLOv3 + Faster R-CNN, 5 classes
- **Wang et al.** (2021)
  YOLOv5 otimizado, mAP 0,90
- **Delhi et al.** (2020)
  SSD MobileNet, detecção de capacete

IA na Borda

- **Shin et al.** (2022)
  YOLO no Jetson Xavier, 45 FPS
- **Ren et al.** (2021)
  TensorRT + DeepStream, veículos
- **Bhatti et al.** (2021)
  YOLO compacto para IoT edge

Trabalhos existentes focam em **poucas classes** (3–5) com **modelo único**. Nenhum combina inferência em **cascata multidomínio** com **computação de borda**.

COMPARAÇÃO COM A LITERATURA

Posicionamento do trabalho frente ao estado da arte em detecção de EPIs e IA na borda

Trabalho	Classes	mAP	FPS	Hardware	Cascata
Nath et al. (2020)	5	0,72	8	RTX 2080	Não
Wang et al. (2021)	5	0,90	45	RTX 3080	Não
Shin et al. (2022)	5	0,82	45	Jetson Xavier	Não
Este trabalho	**46**	**0,71–0,84**	**20**	**Jetson Xavier**	**Sim**

Lacuna 1
Poucas classes ($\leq$5)

Lacuna 2
Sem cascata multi-domínio

Lacuna 3
GPU desktop (não borda)

Este trabalho: 46 classes, cascata multi-domínio, edge deployment (24W)

Lacunas Identificadas

L1: Cobertura limitada de classes

Trabalhos detectam **3–5 classes** (capacete, colete). Ferramentas e maquinário não cobertos.

L2: Ausência de cascata multidomínio

Modelo único para todas as classes. Sem especialização por domínio.

L3: Hardware não compatível com borda

Maioria usa GPUs desktop (RTX 2080/3080). Inviável para canteiros remotos.

Nosso Posicionamento

Contribuição

- ✓ **46 categorias** — 10× mais
- ✓ **Cascata PGIE+SGIEs** por domínio
- ✓ **Jetson Xavier** — 24 W, offline
- ✓ **20 FPS** — 4 modelos

Inédito: cascata multidomínio na borda para segurança em construção civil

Arquitetura de Inferência em Cascata

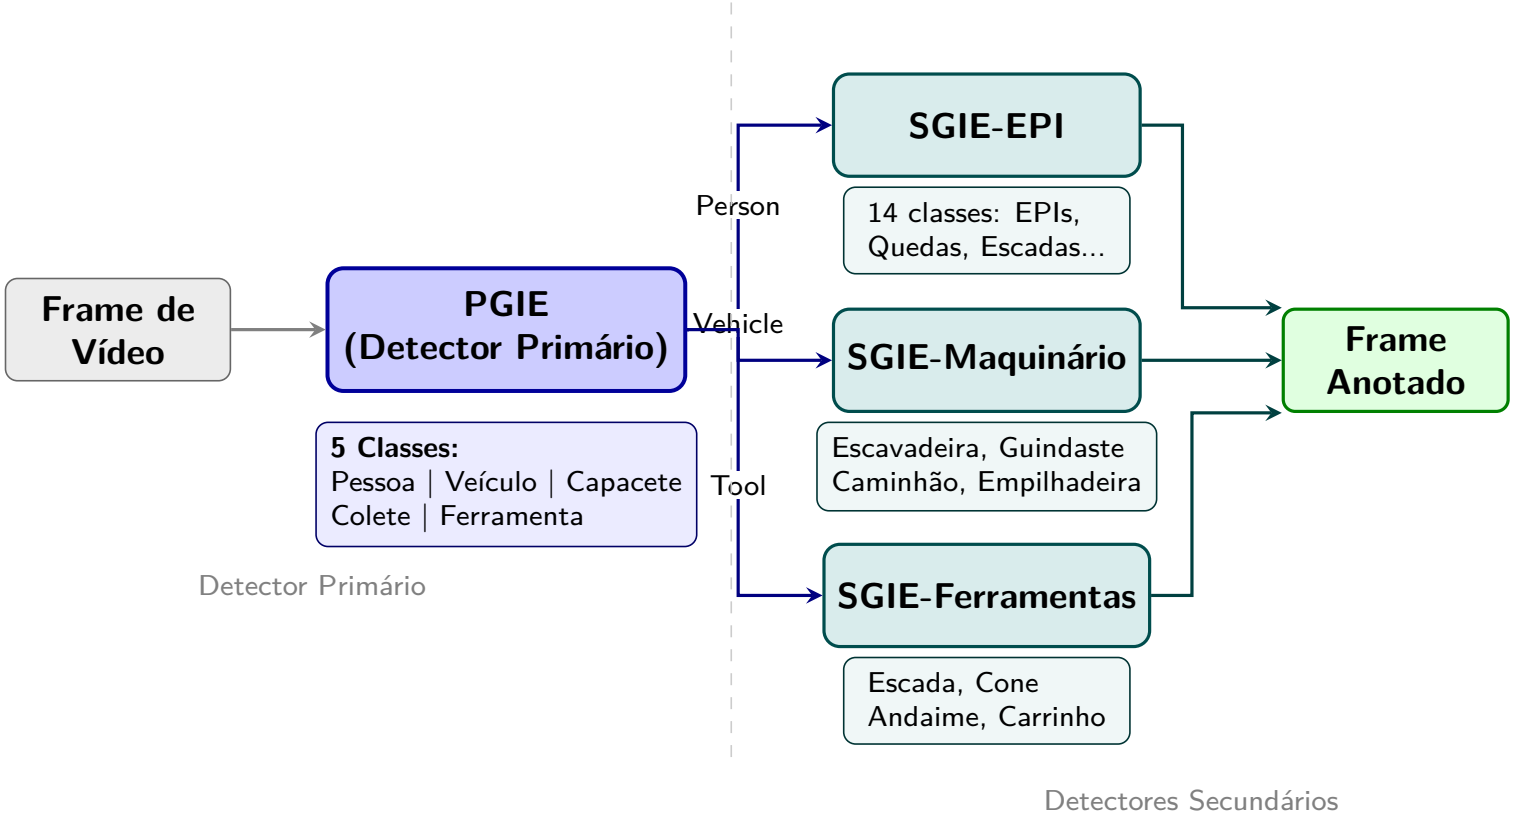

Fluxo: Frame $\xrightarrow{\text{PGIE}}$ 5 classes $\xrightarrow{\text{ROI crop}}$ 3 SGIEs $\rightarrow$ **46 categorias**

Vantagem: cada SGIE opera apenas sobre a ROI relevante — menor carga computacional e maior precisão por domínio.

CLASSES DO SISTEMA

Modelo	Cls.	Entrada	Saída
PGIE	5	Frame	Person, Vehicle, Hardhat, Vest, Tool
SGIE-EPI	14	ROI *Person*	Capacete, colete, óculos, luva, bota...
SGIE-Maq	9	ROI *Vehicle*	Escavadeira, guindaste, betoneira...
SGIE-Fer	23	ROI *Tool*	Serra, furadeira, martelo, andaime...
Total	**46**		**categorias únicas**

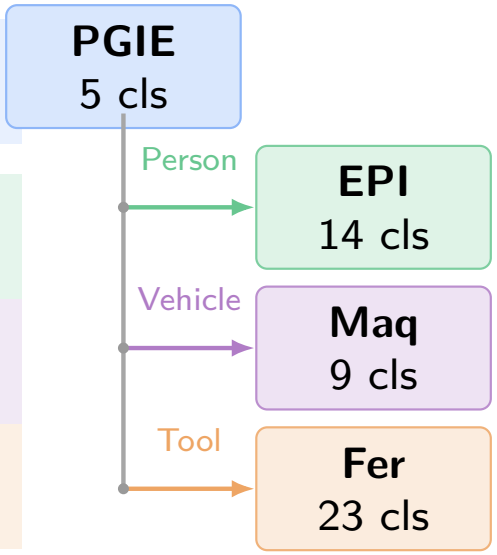

46 categorias únicas: PGIE detecta 5 classes gerais e roteia cada ROI para o SGIE especializado.

DATASETS E CURADORIA

Modelo	Dataset(s)	Cls.	Foco
PGIE	SODA + MOCS + Roboflow Constr.	5	Canteiros reais
SGIE-EPI	SHWD + GDUT-HWD + PPE Det.	14	Capacetes, coletes, EPIs
SGIE-Maq.	Construction Vehicles + Heavy Eq.	9	Maquinario pesado
SGIE-Fer.	Construction Tools + Safety Eq.	23	Ferramentas e materiais

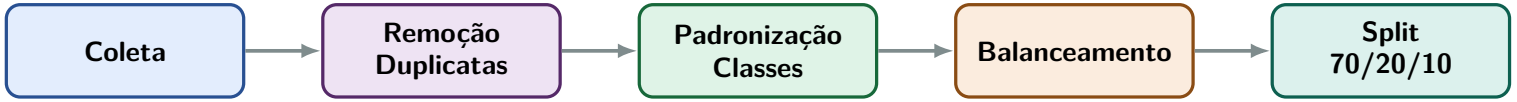

Revisão de anotações, hashing perceptual p/ duplicatas, unificação de labels. Formato **YOLO** — Split: **70/20/10** estratificado.

DISTRIBUICAO DE CLASSES — PGIE

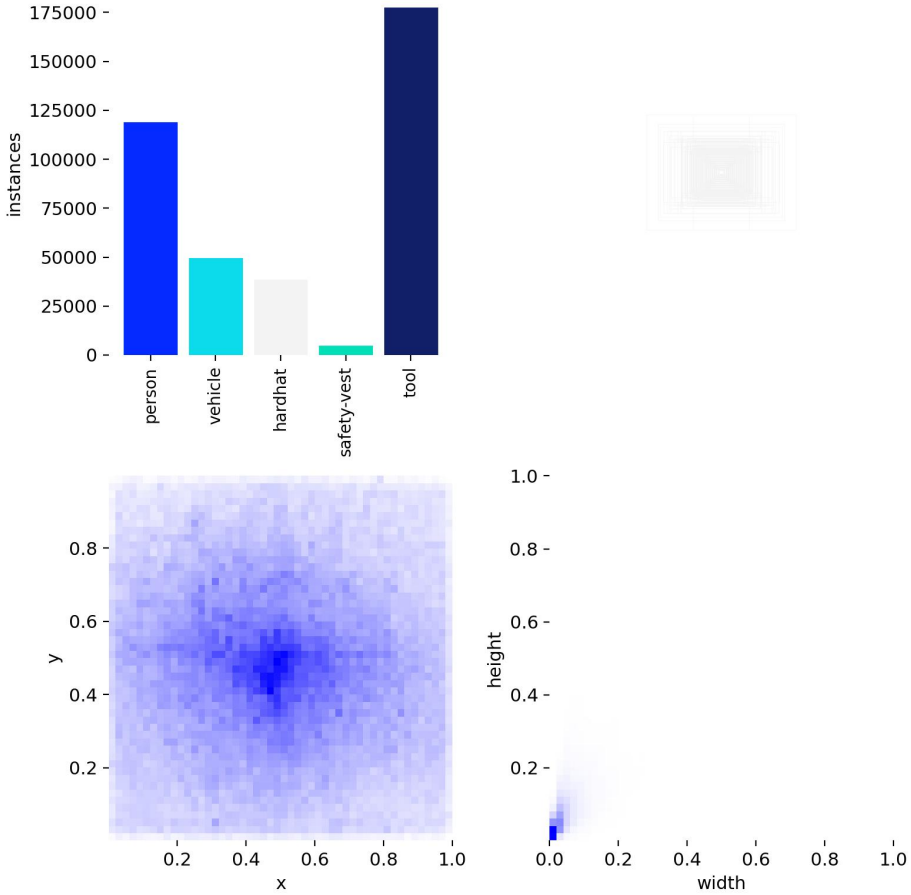

5 classes:

- Person, Vehicle, Hardhat, Safety Vest, Tool
- *Person* predominante
- Desbalanceamento mitigado via augmentation

Concentração central com dispersão uniforme — boa cobertura do campo visual.

DISTRIBUICAO DE CLASSES — SGIES

SGIE-Ferramentas (23 classes)

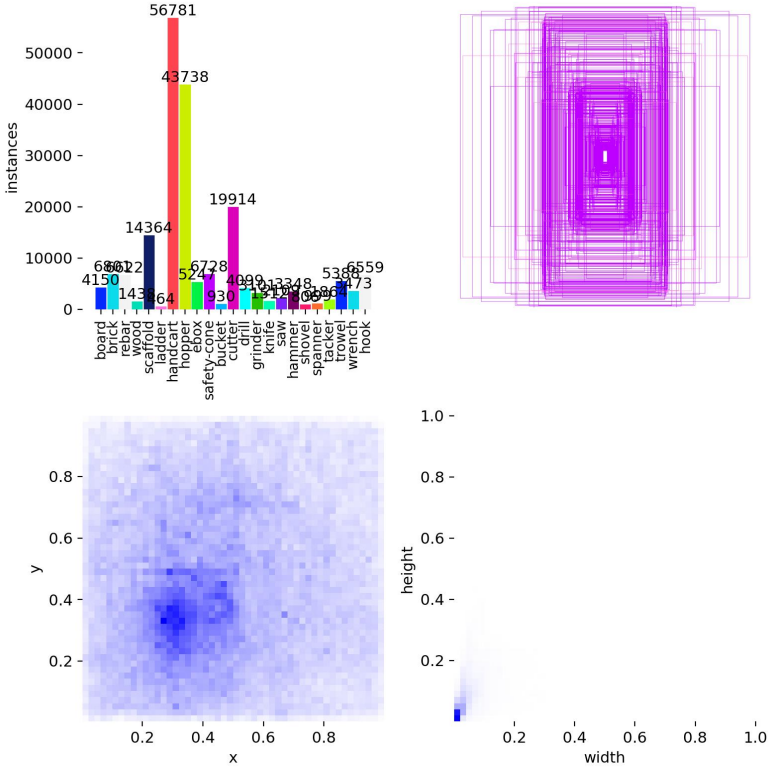

Desbalanceamento significativo entre categorias

SGIE-Maquinario (9 classes)

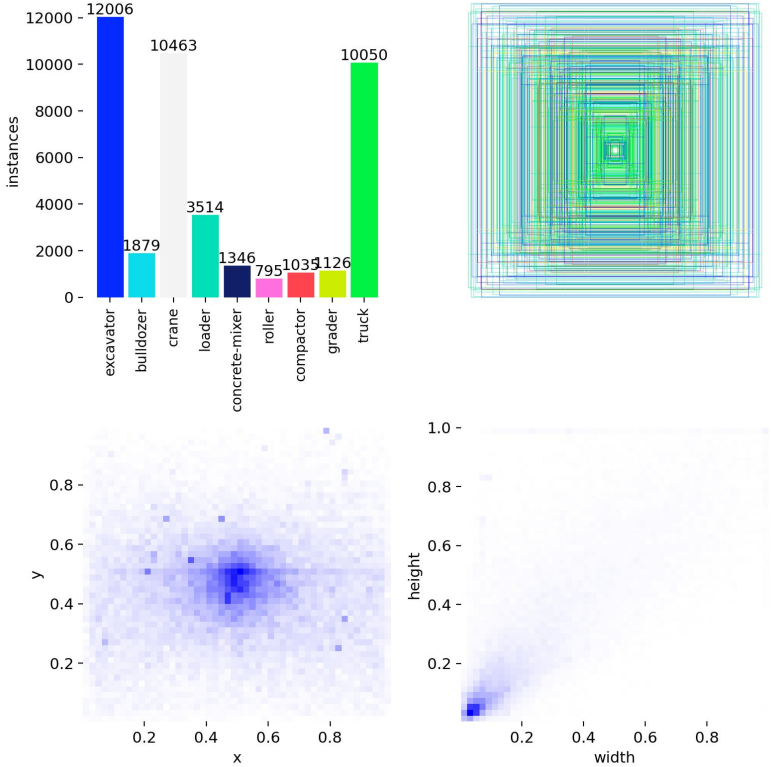

Distribuicao mais equilibrada entre as classes

SGIE-EPI (14 cls): datasets SHWD, GDUT-HWD, PPE Detection — presença/ausência de EPIs com pares positivo/negativo.

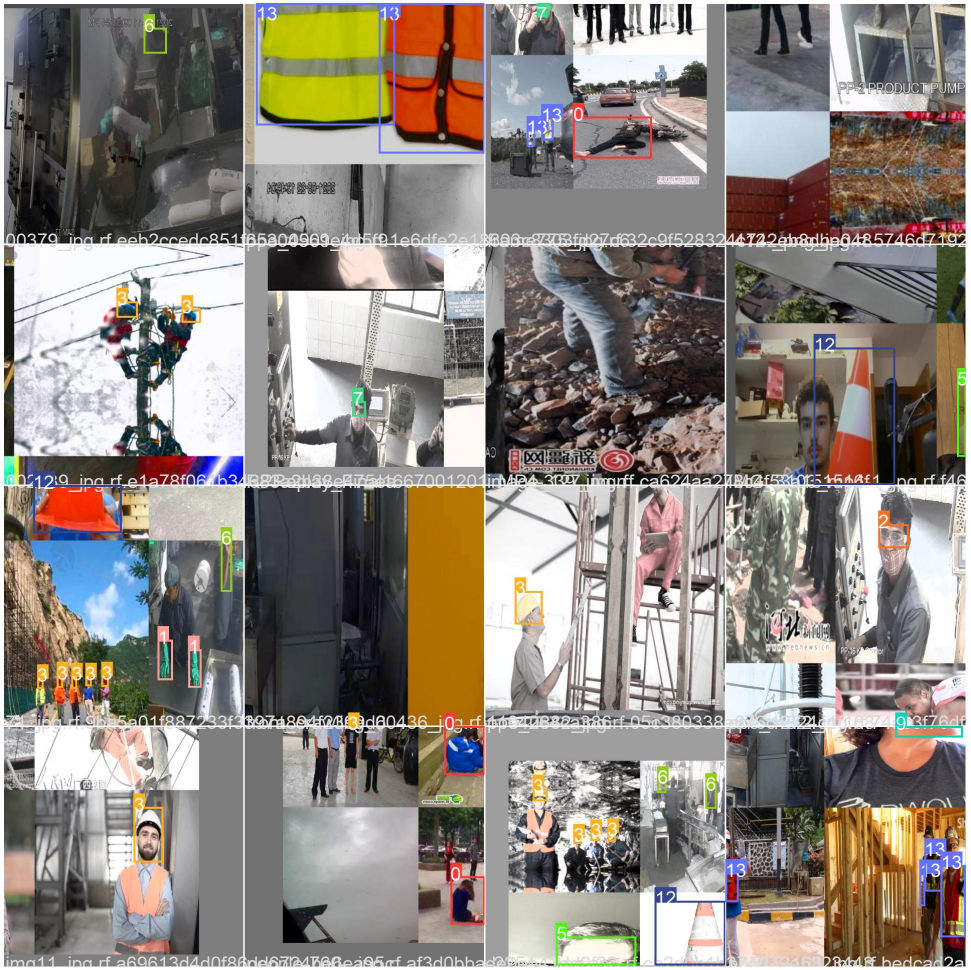

Amostra de batch de treinamento com augmentations aplicadas

Tecnicas e propositos:

- **Mosaic** (p=1.0)
  Multi-escala, contexto variado
- **Flip horizontal** (p=0.5)
  Invariancia a orientacao
- **Escala** (0.5x–1.5x)
  Robustez a tamanhos variados
- **HSV** (h=0.015, s=0.7, v=0.4)
  Invariancia a iluminacao
- **Translacao** (10%)
  Variacao de posicao

Hiperparâmetros

Parâmetro	PGIE	SGIEs
Modelo	YOLOv8m	YOLOv8s
Resolução	640	320
Batch	16	32
Épocas	300	200
Otimizador	SGD	SGD
LR	0,01	0,01
Early stop	50 ep.	30 ep.

Função de Perda

$$\mathcal{L} = \lambda_{box}\mathcal{L}_{box} + \lambda_{dfl}\mathcal{L}_{dfl} + \lambda_{cls}\mathcal{L}_{cls}$$

$\mathcal{L}_{box}$ CIoU — localização da bbox
$\mathcal{L}_{dfl}$ Distrib. Focal — refinamento das bordas
$\mathcal{L}_{cls}$ BCE — classificação do objeto

Pipeline de Otimização

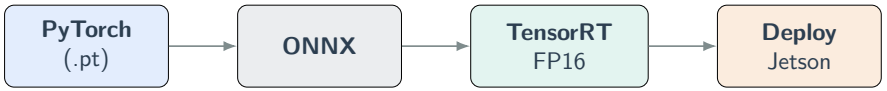

Otimizações TensorRT

- **Quantização FP16**: speedup ∼1,7×
- **Fusão de camadas**: Conv+BN+ReLU
- **Seleção de kernels**: otimizados p/ GPU
- Compilado **diretamente no Jetson**

Ambiente

RTX 4070 (12 GB), PyTorch 2.0, Ultralytics v8.0

Fluxo de vídeo processado pelo pipeline DeepStream no Jetson AGX Xavier.

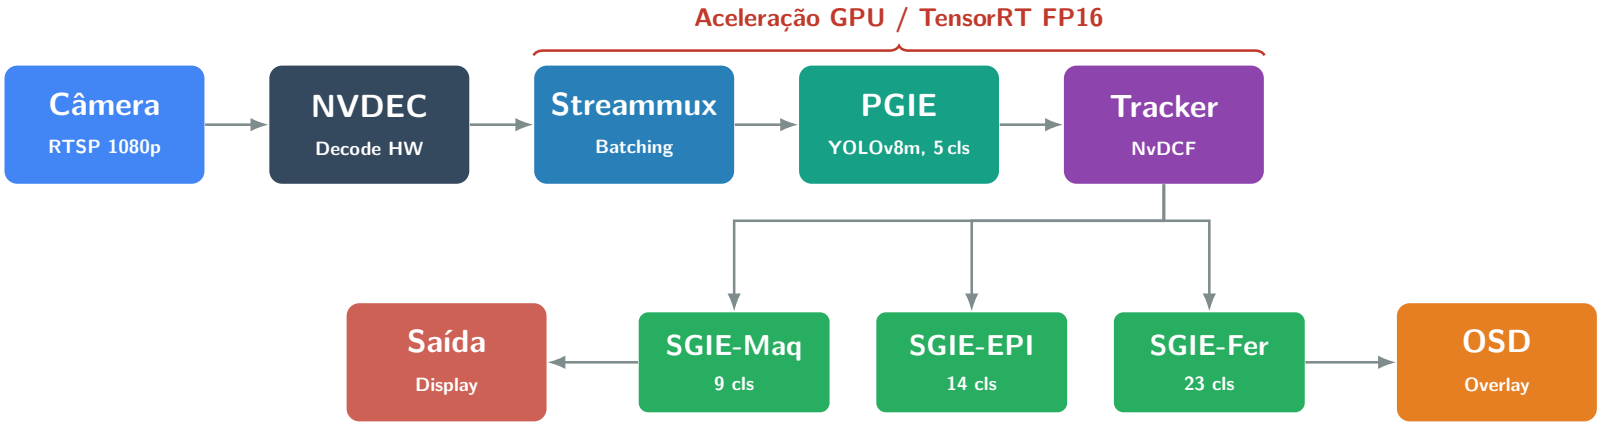

Cascata PGIE → 3 SGIEs com roteamento por classe — **20 FPS** / **58 ms** de latência.

PIPELINE DEEPSTREAM

Pipeline GStreamer com aceleração por hardware — captura → inferência em cascata → alertas.

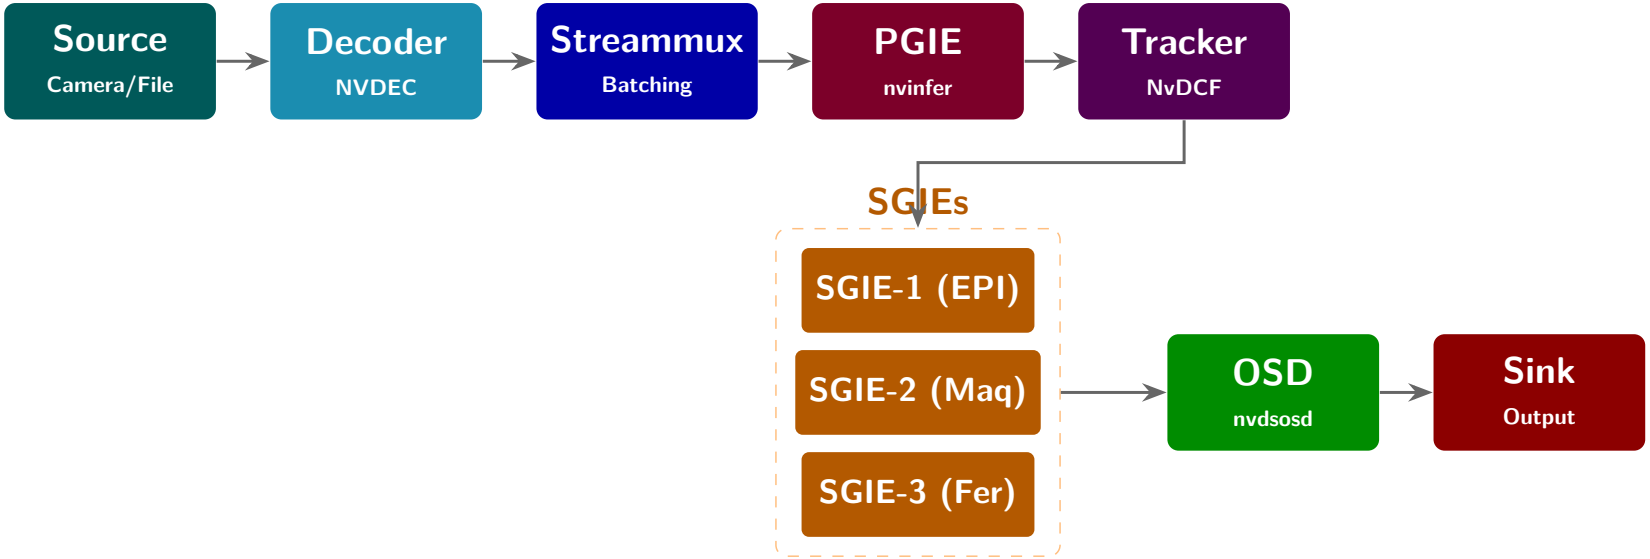

Cada componente é um plugin GStreamer otimizado — aceleração por **GPU/TensorRT** entre Streammux e SGIEs.

Roteamento de detecções do PGIE para SGIEs especializados via ROI recortada.

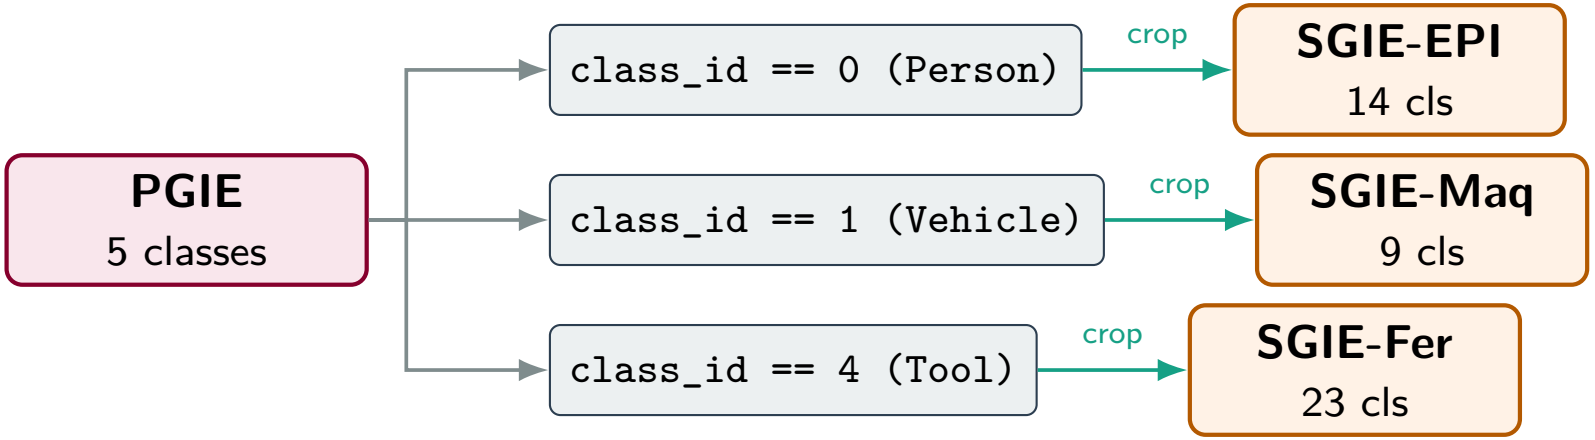

Função do Parser

- Decodifica saída *anchor-free* YOLOv8
- Filtragem por confiança + NMS
- Compilado como `.so` (C++)

Roteamento

- SGIE opera via `operate-on-class-ids`
- ROI recortada da bbox do PGIE
- Processam apenas regiões de interesse

Pilha de software otimizada para inferência em borda no Jetson AGX Xavier.

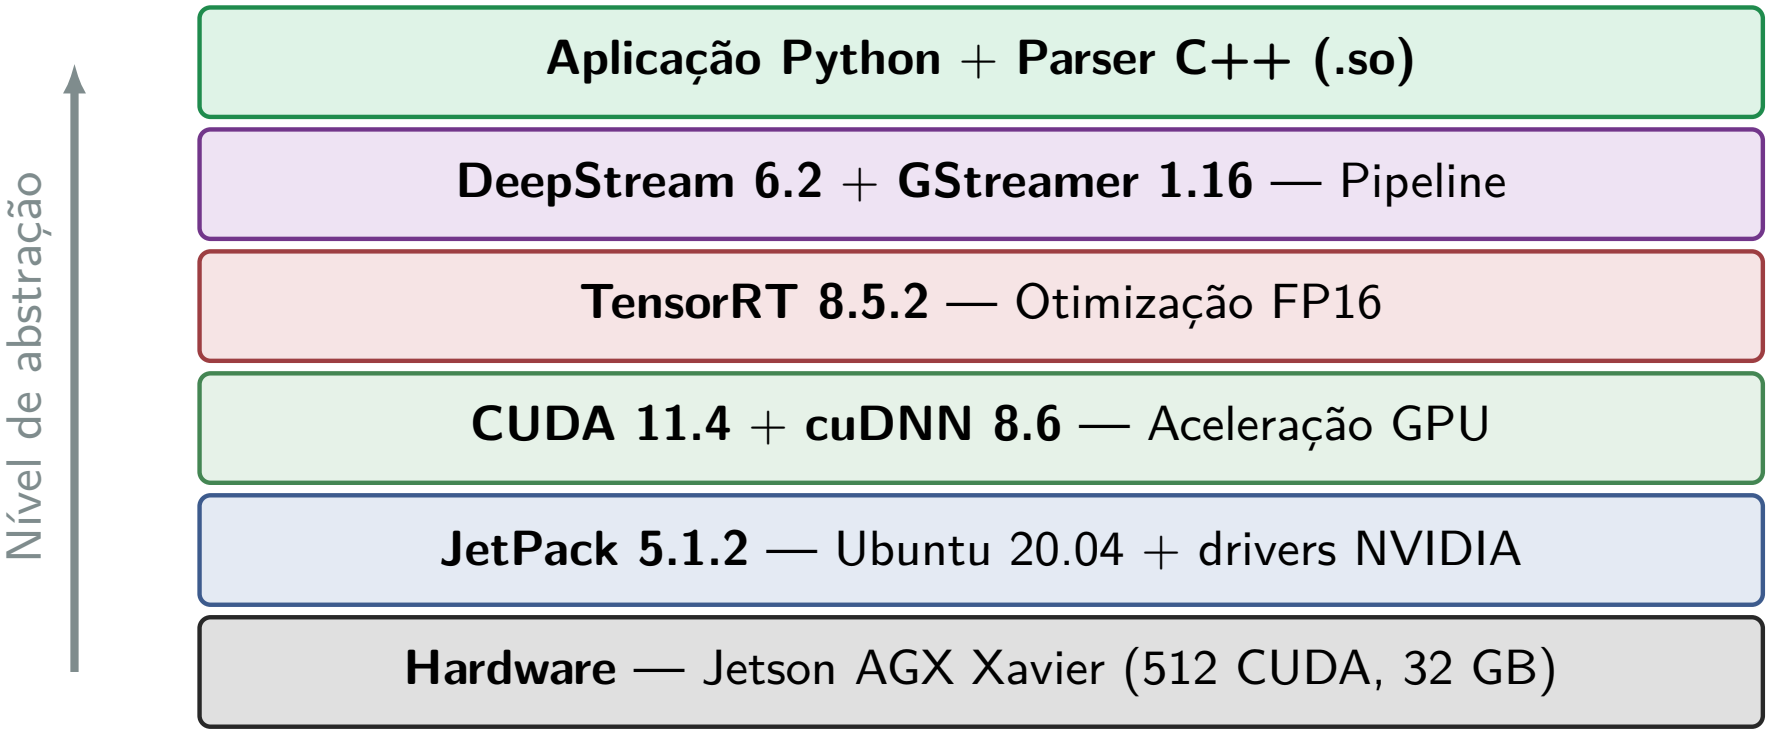

Modelos exportados em **FP16** via TensorRT — speedup de **1,7**× sobre FP32.

Aspectos práticos de implantação do sistema no Jetson AGX Xavier.

Configuração do Dispositivo

- Modo de potência: **MAXN (30 W)**
- 512 CUDA cores ativos
- 8 cores ARM v8.2 a 2,26 GHz
- 32 GB LPDDR4x compartilhada

Entrada de Vídeo

- Stream **RTSP** via rede local
- Decodificação por **NVDEC** (hw)
- 1920×1080 → 640×640

Saída e Visualização

- Display local via `nveglglessink`
- Gravação via `filesink`
- Bboxes + labels + alertas EPI

Otimizações Aplicadas

- Memória unificada CPU-GPU
- Batching de crops para SGIEs
- Pipeline assíncrono (GStreamer)
- Quantização FP16 em todos os modelos

Pipeline completo: **20 FPS** / **58 ms** de latência end-to-end em modo MAXN.

RESUMO DE TREINAMENTO

Visão consolidada dos 4 modelos: arquitetura, resolução, épocas e métricas finais

Métrica	PGIE	SGIE-EPI	SGIE-Maq	SGIE-Fer
Modelo	YOLOv8m	YOLOv8s	YOLOv8s	YOLOv8s
Classes	5	14	9	23
Resolução	640×640	320×320	320×320	320×320
Épocas	187/300	142/200	128/200	156/200
mAP@0,5	**0,83**	0,77	**0,84**	**0,71**
Precisão	0,84	0,80	0,86	0,74
Recall	0,78	0,71	0,79	0,66

SGIE-Maquinário com melhor mAP (0,84) — **SGIE-Ferramentas** com menor (0,71) devido a 23 classes com alta variabilidade

RESULTADOS — VISÃO GERAL

Desempenho consolidado dos quatro modelos treinados (mAP@0,5).

Modelo	Classes	mAP@0,5	Precisão	Recall
PGIE	5	**0,83**	0,84	0,78
SGIE-EPI	14	**0,77**	0,80	0,71
SGIE-Maquinário	9	**0,84**	0,86	0,79
SGIE-Ferramentas	23	**0,71**	0,74	0,66
Total	**46 únicas**	**0,71–0,84**	—	—

▲ Melhor: **SGIE-Maquinário** (0,84) — objetos grandes, visualmente distintos.

▼ Menor: **SGIE-Ferramentas** (0,71) — 23 classes, muitas ferramentas pequenas.

PGIE — CURVAS DE TREINAMENTO

187 épocas, melhor resultado na época 137 (early stopping com paciência de 50).

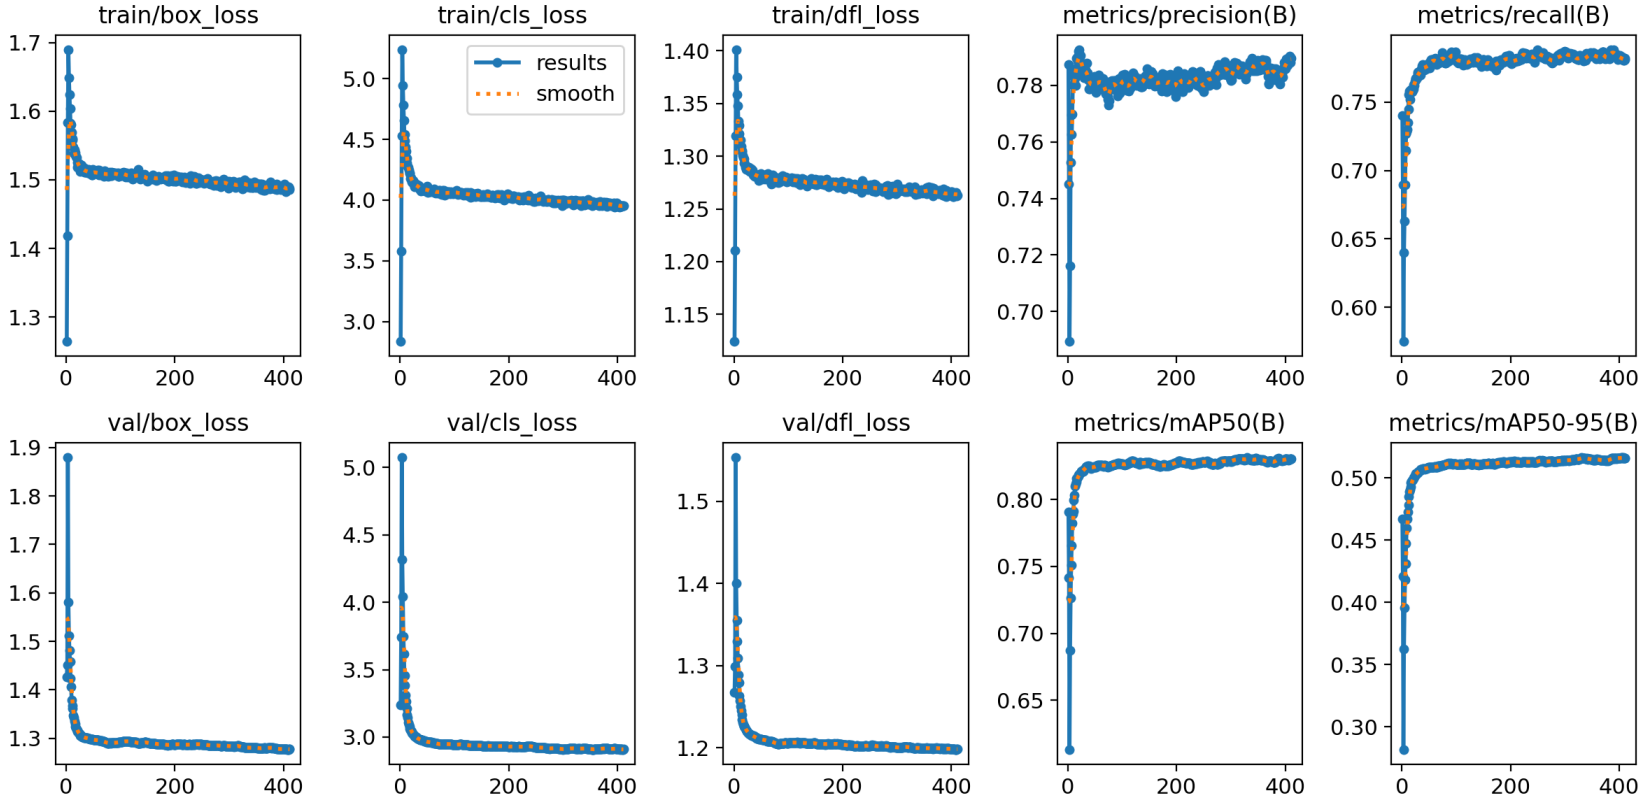

Convergência estável após época 80 — mAP estabiliza em ∼0,83.

PGIE — AVALIAÇÃO

Matriz de confusão normalizada e curvas Precision-Recall (5 classes, mAP@0,5 = 0,83).

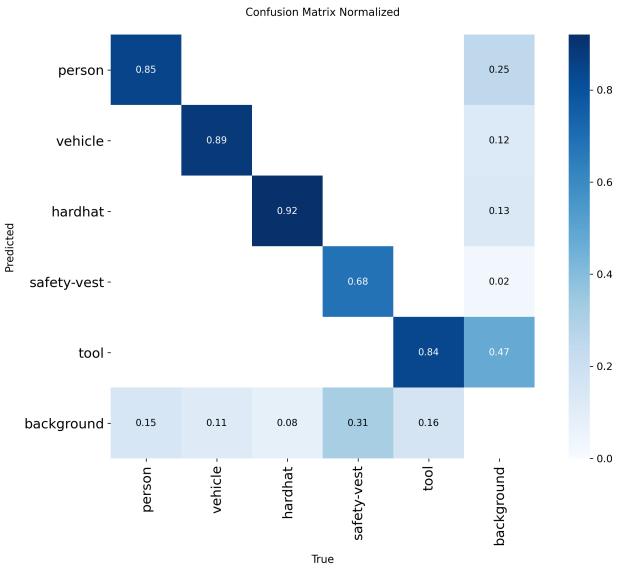

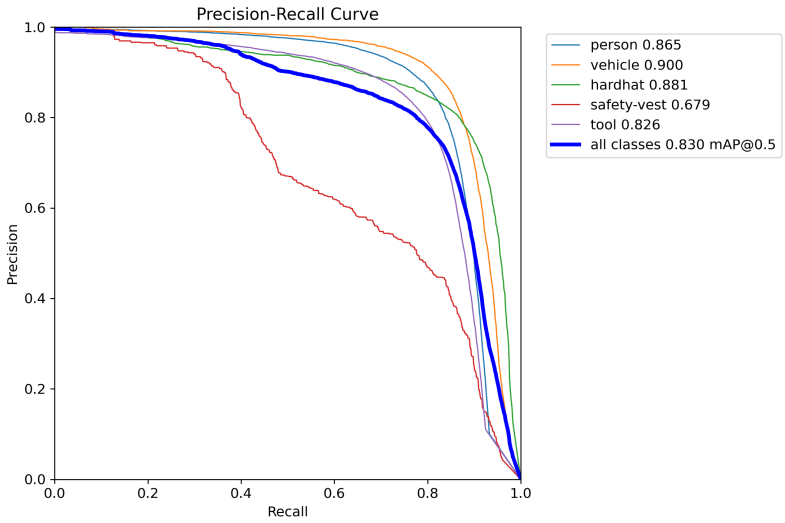

Todas com AP $\geq$ 0,68. Melhor: **Vehicle** (0,90). Pior: **Safety-vest** (0,68) — poucas instâncias (6.500).

SGIE-EPI — AP POR CLASSE

Desempenho das 14 classes de EPI ordenadas por AP@0,5 — mAP geral = 0,77.

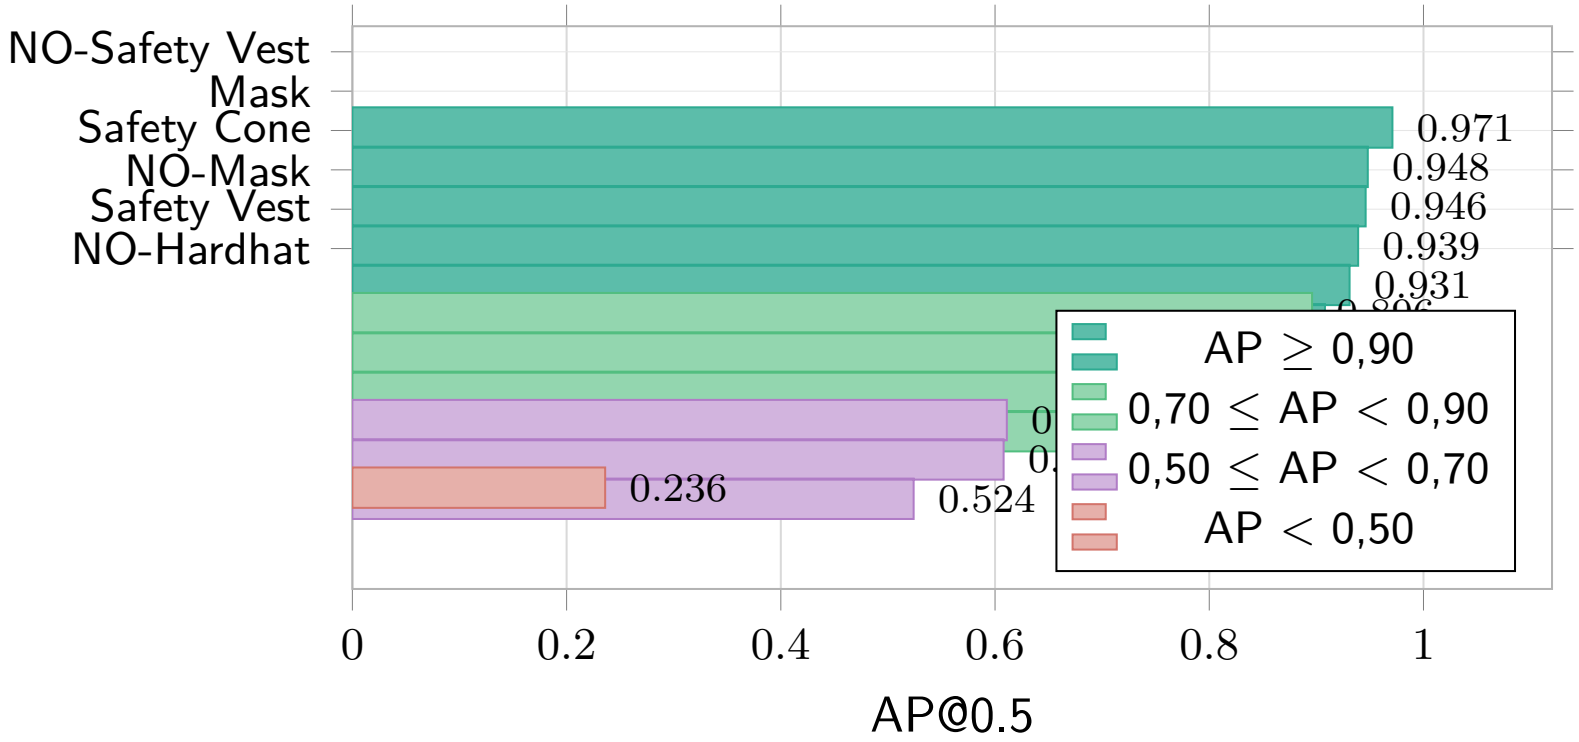

- 6 classes com AP > 0,90 (Goggles, Gloves, Ladder, NO-Goggles, Person, NO-Gloves).
- NO-Safety Vest (0,24) — poucas amostras (890).

Matriz de confusão e curvas PR para 14 classes de EPIs e situações de risco.

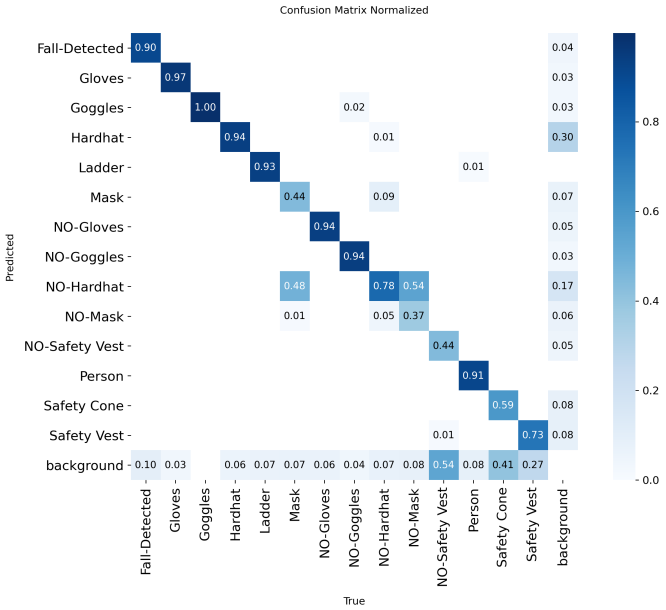

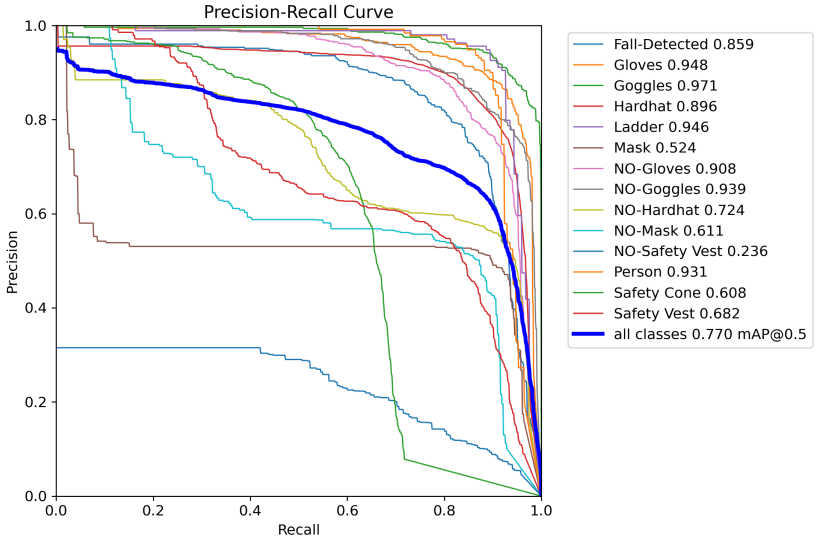

Matriz de confusão (esq.): diagonal forte = boa separação; confusões em pares presença/ausência (Vest ↔ NO-Vest, Mask ↔ NO-Mask).

Curvas PR (dir.): **mAP@0,5 = 0,77** — melhores: Gloves (0,95), Goggles (0,97); piores: NO-Safety Vest (0,24), NO-Mask (0,61) por ambiguidade visual.

Matriz de confusão e predições na validação para 9 classes de maquinário pesado.

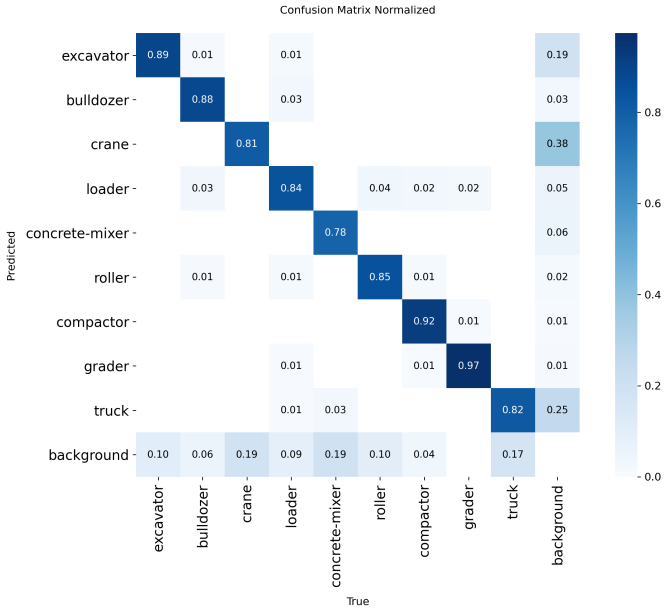

Matriz de confusão (esq.): diagonal quase perfeita — objetos grandes e visualmente distintos facilitam a classificação. **Predições** (dir.): bboxes corretas em escavadeiras, caminhões e guindastes em cenas reais de canteiro.

mAP@0,5 = 0,84 — melhor SGIE. Melhor classe: Excavator (0,91). Menor: Grader (0,77) por escassez de amostras (350).

SGIE-FERRAMENTAS — AVALIAÇÃO (**23 CLASSES**)

Matriz de confusão e predições na validação para 23 classes de ferramentas e materiais.

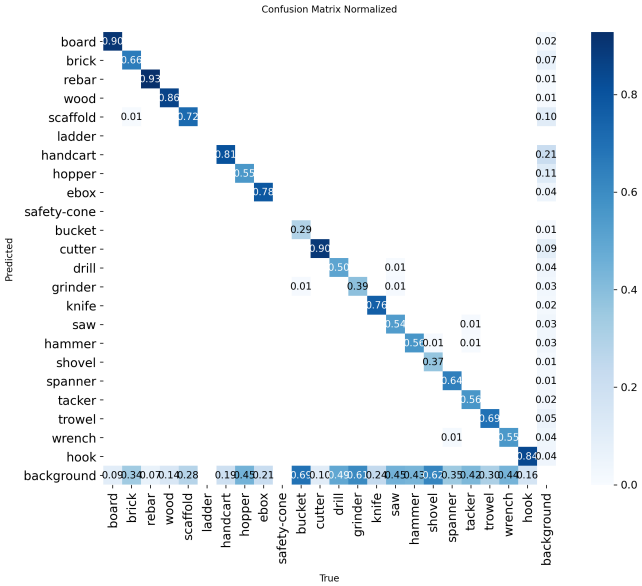

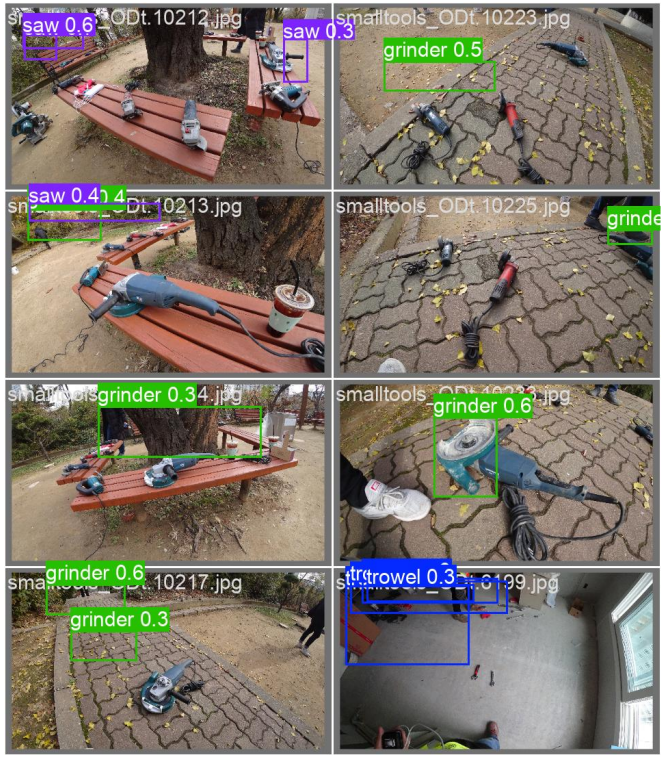

Matriz de confusão (esq.): diagonal visível mas com dispersão — 23 classes com alta variabilidade de tamanho e forma.

Predições (dir.): detecções corretas em cenas com múltiplas ferramentas sobrepostas (serras, furadeiras, escadas).

Objetos grandes (Cone: 0,86 / Ladder: 0,82) **superam 0,80**; pequenos (Cutter: 0,54 / Trowel: 0,56) **abaixo de 0,60** por tamanho reduzido.

PERFORMANCE DO PIPELINE — JETSON AGX XAVIER

Throughput (FP16)

Configuração	FPS
Apenas PGIE	38
PGIE + SGIE-EPI	28
Pipeline completo	**20**
Pipeline FP32	12

FP16: speedup de **1,7**× vs FP32

Latência por Componente

Componente	ms	%
Decodificação	5,0	9%
PGIE (inferência)	**18,5**	**32%**
SGIE-EPI	8,4	14%
SGIE-Maquinário	7,8	13%
SGIE-Ferramentas	7,2	12%
Tracker	4,8	8%
OSD + Render	6,3	11%
Total	**58,0**	100%

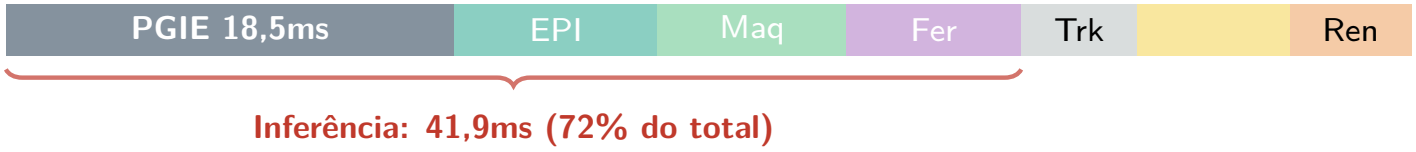

UTILIZAÇÃO DE RECURSOS — JETSON AGX XAVIER

Recurso	Valor
GPU	**82%**
CPU (8-core)	38%
RAM	5,8 GB / 18%
Consumo	24 W
Temperatura	56 °C

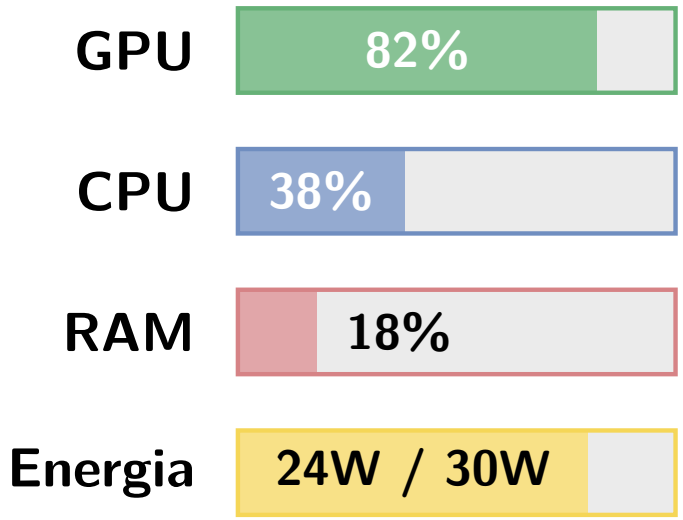

Gargalo

GPU é o recurso limitante. CPU e RAM com **folga significativa**.

Otimização Possível

Quantização **INT8** ou uso de **DLA** (Deep Learning Accelerator).

PROPAGAÇÃO DE ERROS — PIPELINE END-TO-END

Propagação de Erros no *Pipeline* em Cascata

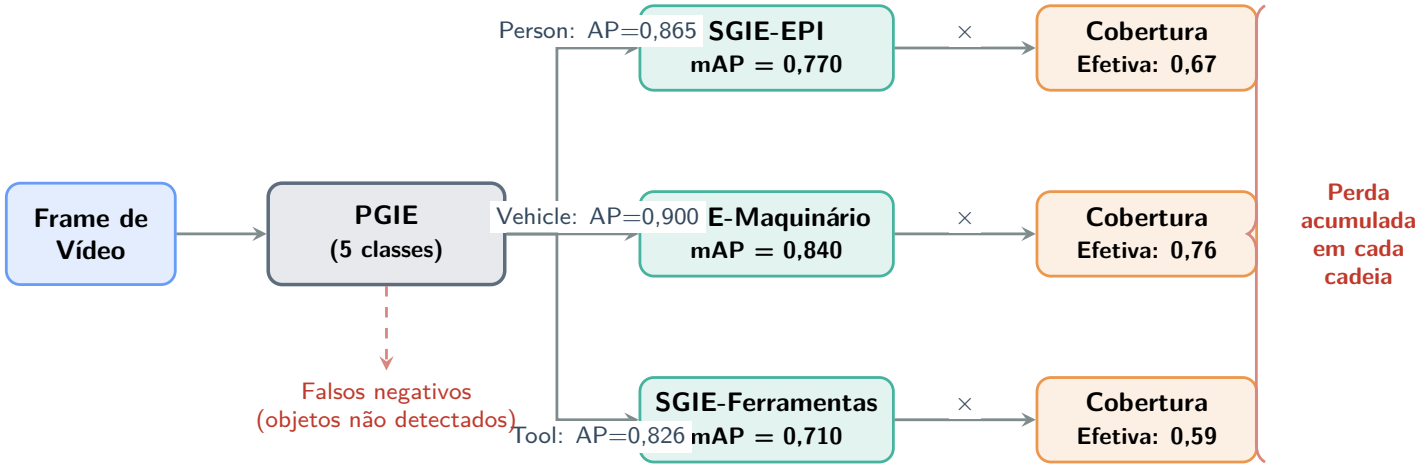

Cobertura Efetiva $\approx AP_{PGIE} \times mAP_{SGIE}$

Cadeia	AP PGIE	mAP SGIE	Cobertura Efetiva
Person → EPI	0,865	0,770	**0,67**
Vehicle → Maq	0,900	0,840	**0,76**
Tool → Fer	0,826	0,710	**0,59**

Cobertura $\approx AP_{PGIE} \times mAP_{SGIE}$. Ferramentas perde **41%**. Mitigação: reduzir threshold do PGIE.

COMPARAÇÃO COM A LITERATURA

Trabalho	Classes	mAP@0,5	FPS	Hardware	Cascata
Nath et al. (2020)	5	0,72	8	RTX 2080	Não
Wang et al. (2021)	5	0,90	45	RTX 3080	Não
Shin et al. (2022)	5	0,82	45	Jetson Xavier	Não
Este trabalho	**46***	**0,71–0,84**	**20**	**Jetson Xavier**	**Sim**

* 46 categorias únicas (5 PGIE + 14 EPI + 9 Maq + 23 Fer)

10×
mais classes que
trabalhos relacionados

4
modelos em cascata
na mesma GPU

24W
edge deployment
sem nuvem

Abordagem inédita: inferência multiestágio em cascata na borda para monitoramento de segurança

RESULTADOS QUALITATIVOS — DETECÇÕES DO SISTEMA

SGIE-Ferramentas (23 classes)

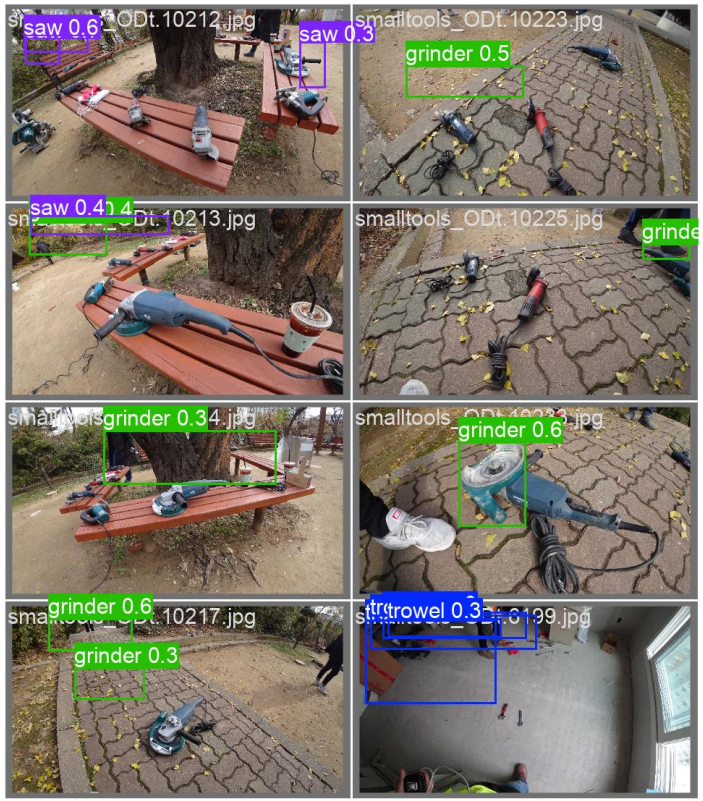

SGIE-Maquinário (9 classes)

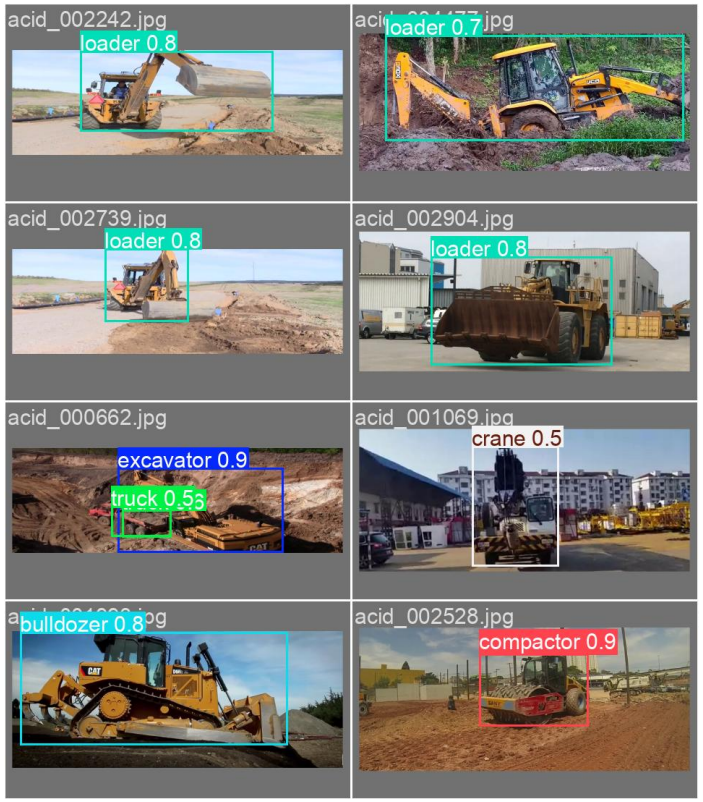

Predições na validação demonstram detecção de **múltiplos objetos simultâneos** com classes corretas. Modelos diferenciam objetos visualmente similares (Drill vs. Grinder).

CONCLUSÕES

46

Categorias Únicas — Cascata PGIE + 3 SGIEs para **EPIs**, **maquinário pesado** e **ferramentas**.

0,71–0,84

mAP@0,5 — PGIE: 0,83 / EPI: 0,77 / Maq: **0,84** / Fer: 0,71.

20 FPS
58 ms

Tempo Real — Pipeline completo com 4 modelos simultâneos.

24 W

Computação na Borda — Jetson AGX Xavier, sem nuvem.
Aplicável em canteiros remotos com conectividade limitada.

OBJETIVOS ATINGIDOS

Mapeamento entre objetivos específicos (OE1–OE4) e resultados alcançados

OE1: Treinar 4 modelos YOLOv8
PGIE (5 cls) + 3 SGIEs especializados
→ ✓ mAP: 0,83 / 0,77 / 0,84 / 0,71
46 categorias únicas treinadas e validadas

OE2: Pipeline DeepStream em cascata
PGIE → SGIEs com rastreamento
→ ✓ 20 FPS / 58 ms latência end-to-end
Pipeline funcional com 4 modelos simultâneos

OE3: Parser C++ YOLOv8–DeepStream
Roteamento PGIE → SGIEs por classe
→ ✓ Biblioteca .so compilada e integrada
Decodificação anchor-free + NMS + roteamento

OE4: Avaliação de desempenho
Acurácia, velocidade e recursos
→ ✓ GPU 82% | RAM 18% | 24 W
Métricas completas no Jetson AGX Xavier

Todos os **4 objetivos específicos** foram atingidos — sistema funcional validado no Jetson AGX Xavier

LIMITAÇÕES E TRABALHOS FUTUROS

Limitações

- **Propagação de erros** — cobertura efetiva 0,59–0,76
- **Objetos pequenos** — AP $<$ 0,60 (Cutter, Trowel)
- **Validação controlada** — benchmark, sem canteiro real
- **Dataset sem dados locais** — canteiros BR não representados
- **Desbalanceamento** — NO-Safety Vest: AP=0,236

Trabalhos Futuros

- ✓ **SAHI** para objetos pequenos
- ✓ **Dataset brasileiro** com classes sub-representadas
- ✓ **YOLOv9 / YOLOv10 / RT-DETR**
- ✓ **Piloto em canteiro real** (NR-18)
- ✓ **Quantização INT8 + DLA** (>30 FPS)

IMPACTO E APLICABILIDADE REAL

2.538

mortes na construção civil brasileira (2012–2021)

Fonte: SmartLab / MPT / OIT

NR-18

Conformidade automatizada com norma de segurança

Cenários de Implantação

- **Grandes construtoras**
  - Alertas 24h em tempo real
- **Obras públicas**
  - Fiscalização NR-18 automatizada
- **Canteiros remotos**
  - Edge AI operando a 24W
- **Seguradoras**
  - Avaliação de risco automatizada

Tecnologia acessível: Jetson AGX Xavier (~US$ 700) + câmera IP — custo operacional mínimo.

Obrigado!

Perguntas?

Monitoramento de Segurança em Canteiros de Obra utilizando Inferência Multiestágio em Inteligência Artificial na Borda

Luiz Guilherme Martinho Sampaio Ito

Orientador: Prof. Dr. José Rodrigo Furlanetto de Azambuja

guilherme.ito@ufrgs.br

Instituto de Informática — UFRGS
Programa de Pós-Graduação em Computação

Março de 2026